

Resumen completo de genómica

Actividad previa, clases 1 a 3 y los dos trabajos prácticos, ordenados para estudiar de principio a fin.


0	El genoma humano por dentro	ACTIVIDAD PREVIA
1	Ómicas, regulación y validación	CLASE 1
2	Proyecto Genoma Humano y NGS	CLASE 2
3	Variación, poblaciones y bases de datos	CLASE 3
4	TP 1 · Del FASTQ a la variante	TRABAJO PRÁCTICO 1
5	TP 2 · Anotar, filtrar y clasificar	TRABAJO PRÁCTICO 2
6	cfDNA prenatal: la genómica en la clínica	ACTIVIDAD PREVIA
A	Anexos: tablas, criterios ACMG y glosario	RECURSOS

Armado a partir de tus resúmenes de la materia. La parte de transcriptómica y proteómica no está incluida: no entra en el primer parcial y no forma parte de este material.

Mapa mental de la materia

Mapa mental · lo que entra en el primer parcial

Genómica: actividad previa, clases 1 a 3 y los dos trabajos prácticos



Las ocho ramas que entran en el parcial. Lo resaltado es lo que más aparece en los exámenes.

Genotipo, fenotipo y todo lo que hay en el medio

El **genotipo** es la secuencia de ADN de una persona (nuclear + mitocondrial). El **fenotipo** es todo lo demás: no sólo lo visible, también ser celíaco, intolerante a la lactosa, el metabolismo, la susceptibilidad a enfermedades o la respuesta a un fármaco. Sobre el fenotipo pesan además el **ambiente**, la **historia de vida** y la **epigenética**.

GENOTIPO + AMBIENTE + HISTORIA DE VIDA + EPIGENÉTICA = FENOTIPO

Todas tus células tienen prácticamente el mismo ADN: lo que hace distinta a una neurona de un hepatocito es **qué genes se expresan**, regulado en parte por cuán compactada está cada región de cromatina. El genoma *condiciona* pero no *determina*: la partitura es fija, la interpretación no.

Qué hay adentro de los $3,2 \times 10^9$ pb

- **Sólo 2-3% codifica proteínas** (~23.000 genes). Los exones son ~1% del genoma.
- **Genes de ARN no codificante** (~3000): ARNt, ARNr, miARN, siARN, lncRNA. No todo ARN se traduce.
- **Elementos reguladores**: promotores, enhancers, silencers, sitios de unión de factores de transcripción. Pueden estar lejos del gen, incluso en otro cromosoma.
- **Repetitivas**: LINE (~21%), SINE (~13%, p. ej. *Alu*), minisatélites, microsatélites, telómeros, pseudogenes.
- **Familias génicas** por duplicación + divergencia (globinas, actinas, receptores olfativos).

La pregunta que cae seguro

Un genoma más grande **no** implica más genes ni más complejidad: la diferencia de tamaño entre genes se explica sobre todo por la **longitud de los intrones** (los exones miden ~200 pb en promedio). Y los humanos no somos ni la especie con más genes ni la del genoma más grande.

Un genoma, muchas más proteínas

No se puede deducir el proteoma sólo de la secuencia, porque:

- **Splicing alternativo**: distintas combinaciones de exones (siempre en el orden del genoma). ~95% de los genes multiexónicos generan variantes.
- **Promotores alternativos y edición de ARN** (A→I, que se lee como G; C→U en mitocondrias de plantas). Puede ser tejido-específica.
- **Excepción del sistema inmune**: 10^8 – 10^{10} anticuerpos por **recombinación del ADN** (no del ARN).
- **Pseudogenes**: derivados de genes reales que perdieron función; los que vienen de retrotranscripción de un ARNm **no tienen intrones**.

Organización: cómo se guarda todo eso

Procariotas Una molécula circular asociada a proteínas = **nucleoide**, más **plásmidos** (resistencia a antibióticos, vectores).

Eucariotas ADN lineal en el núcleo → histonas → **nucleosoma** (~146 pb) → fibra de 30 nm → cromatina → cromosoma mitótico. 46 cromosomas: 22 pares de autosomas + sexuales.

Orgánulos Mitocondrias y cloroplastos tienen ADN **circular, sin histonas**, y ribosomas de tipo procariota → evidencia de la **teoría endosimbiótica** (mitocondria ~ Rickettsia; cloroplasto ~ cianobacteria). Muchos de sus genes migraron al núcleo.

Encontrar genes en una secuencia cruda

Después de secuenciar tenés A/T/G/C sin marcas. Se buscan **ORFs** (de ATG a codón stop) en los **6 marcos de lectura** posibles, más señales: caja TATA, GT al inicio del intrón, AG al final, codón stop, señal de poliadenilación, uso de codones no aleatorio.

- **Métodos a priori**: patrones en la propia secuencia.
- **Métodos por comparación**: homología con genes/proteínas conocidos, ESTs, ADNc, conservación evolutiva.
- Es más fácil en procariotas (~90% del genoma de *E. coli* es codificante, sin intrones) que en eucariotas.

Elementos transponibles (~45% del genoma)

Descubiertos por **Barbara McClintock** en maíz (mosaicos de pigmentación).

Clase I • Retrotransposones

Se mueven vía un intermediario de ARN.

LINE

(1-5 kb, codifican transcriptasa reversa, L1 ~20.000 copias) y

SINE

(200-300 pb, cientos de miles de copias, usan la maquinaria de los LINE; *Alu*).

Clase II • Transposones de ADN

Sin intermediario de ARN. Codifican

transposasa

. Cortar y pegar, o copiar y pegar. La escisión puede ser imprecisa y dejar mutaciones.

Efectos: knockout por inserción, cambios de regulación o de splicing, nuevas isoformas, fusiones génicas, reorganizaciones (inversiones, translocaciones, deleciones — p. ej. las asociadas a Prader-Willi/Angelman). La célula los silencia con **metilación** y **siARN**; la hipometilación puede reactivarlos.

Genética vs. genómica (y por qué la materia es "genómica funcional")

Genética	Genes individuales, su estructura, función y herencia.
Genómica	El genoma completo y las relaciones entre todos sus elementos.
Genómica funcional	La pregunta real de la materia: cómo la información del genoma se convierte en función biológica. Qué genes se expresan, cuándo, dónde, en qué cantidad.

Una hoja al sol y una hoja a la sombra tienen el mismo genoma pero **distinto transcriptoma**. Una función normal o alterada es el resultado de todas las regulaciones que van del ADN a la proteína.

Qué molécula estudio y con qué técnica

MOLÉCULA	QUÉ IMPORTA	TÉCNICAS
ADN (estable)	La secuencia	Sanger, NGS 2ª y 3ª gen, PCR, Southern blot
ARN (dinámico)	Secuencia y sobre todo abundancia	NGS previa retrotranscripción a ADNc, RT-qPCR, Northern blot
Proteínas (dinámicas)	Sobre todo abundancia ; también secuencia	Espectrometría de masas, ELISA, Western blot. No se pueden estudiar por NGS: son aminoácidos, no nucleótidos

El zoológico de las ómicas

Transcriptoma

Todos los ARN de una célula en un momento y condición dados. Codificantes (ARNm) y no codificantes (lncRNA, miRNA).

Proteoma

Todas las proteínas en un momento y condición. Variantes: cuantitativa, de interacciones, de orgánulos, fosfoproteómica, PTMs.

Metaboloma

Todos los metabolitos (lípidos, glúcidos, glicanos, aminoácidos). Subcampos: lipidómica, glicómica.

Epigenoma

Metilación del ADN, modificaciones de histonas, organización de la cromatina. No cambia la secuencia.

Metagenómica

Material genético de una comunidad entera tomada del ambiente,
sin cultivar

Microbioma

El conjunto de microorganismos de un ambiente (intestino, piel) junto con su información genética.

Con hipótesis y sin hipótesis

Las ómicas pueden ser **hypothesis-driven** o **discovery-driven** (“libres de hipótesis”). En el segundo caso el recorrido se invierte:

datos masivos → diferencias/patrones → hipótesis → validación experimental

No reemplaza al método científico: lo alimenta. Ventaja clave: **reduce el sesgo del investigador**, que suele plantear hipótesis sólo sobre lo que ya conoce. El paper de la clase (*Big data and experimental biology*) concluye que los dos enfoques son **complementarios**, que una lista de genes o un Gene Ontology **no alcanzan** (hay que construir un modelo biológico) y defiende reutilizar bases públicas con principios **FAIR**.

Ejemplo listo para el examen

Con hipótesis: “los pacientes con diabetes tipo 2 expresan menos genes de secreción de insulina” → RNA-seq de páncreas caso/control → validación por RT-qPCR. **Sin hipótesis:** proteómica de tumor vs. tejido sano sin buscar nada puntual → aparecen proteínas de respuesta inmune aumentadas → *nueva* hipótesis: “la activación inmune participa en el crecimiento tumoral” → se testea con knockout o inhibición.

Los tres niveles de validación ★

NIVEL	PREGUNTA QUE RESPONDE	CÓMO SE HACE
Técnica	¿La medición es correcta o es un artefacto del método?	Confirmar el hallazgo (microarray, RNA-seq, NGS) con una técnica independiente: RT-qPCR, ddPCR, Sanger . Evaluar sensibilidad, especificidad, precisión, límite de detección. Aun con corrección FDR hay falsos positivos.
Biológica	¿Se repite en muestras independientes o fue casualidad de esa muestra/lote?	Réplicas biológicas, cohorte independiente. En GWAS: replicar la asociación en otra población .
Funcional	¿El gen/variante causa el fenotipo o sólo está asociado?	Knockout, knockdown, sobreexpresión, CRISPR, ensayos reporteros (luciferasa), modelos animales. Es la que pasa de correlación a causalidad .

Orden habitual: técnica → biológica → funcional (no es regla estricta).

Los dos casos de la clase

Svante Pääbo (Nobel 2022)

¿Qué relación evolutiva hay entre *H. sapiens* y homínidos extintos? ADN antiguo degradado y contaminado → primero

ADN mitocondrial

(miles de copias por célula), después genoma nuclear. Resultado: neandertales y denisovanos se cruzaron con nosotros (1-4% neandertal en Europa/Asia, hasta 6% denisovano en Melanesia), con genes que aún influyen (inmunidad,

EPAS1

y la altura en tibetanos). Imposible con biología molecular clásica: hacía falta NGS + bioinformática + genómica comparativa.

C4 y esquizofrenia

Del locus MHC (asociado por GWAS con ~37.000 casos y 113.000 controles) al gen causal:

C4

, sobre todo C4A. Más expresión de C4A = más riesgo. C4 se expresa en neuronas, se localiza en sinapsis y los ratones knockout tienen

menos poda sináptica

. Por qué mirar el cerebro si la variante está en todas las células: porque el ADN es el mismo, pero la

expresión

y la función son tejido-específicas.

No confundir

Fibrosis quística: hereda dos alelos patogénicos de *CFTR* (uno de cada padre) → enfermedad; con uno solo, portador sano.

Esquizofrenia: se heredan variantes de **susceptibilidad** que aumentan el riesgo y por sí solas no alcanzan. Somos >99,9% iguales: ese <0,1% explica buena parte de la variabilidad.

HGP vs. Celera: la misma química, distinta estrategia

Los dos usaron **Sanger automatizado** (ddNTP fluorescentes que cortan la síntesis). Lo que cambió fue cómo **fragmentaron, ordenaron y ensamblaron**.

	PROYECTO PÚBLICO (FRANCIS COLLINS)	CELERA (CRAIG VENTER)
Método	<i>Hierarchical / clone-by-clone shotgun</i>	<i>Whole-genome shotgun</i>
Lógica	Primero orden , después secuencio	Primero secuencio todo , después ordeno con la computadora
Pasos	Fragmentos grandes → clonados en BAC → ubicados con STS, fingerprinting y FISH → mapa físico → cada BAC se refragmenta → Sanger → ensamblado	Fragmentación masiva directa → 27,27 M de lecturas propias (~543 pb, 5 individuos) → algoritmos buscan solapamientos. Sumó datos públicos del HGP: >43 M de lecturas en total
Por qué fue más rápido	—	Se saltó casi todo el mapeo físico previo + automatización + capacidad computacional + datos públicos del HGP

Otros datos del proyecto: internacional y público desde **1990**, con la política de publicar las secuencias **dentro de las 24 h** del ensamblado; antes se secuenciaron organismos más chicos (levadura, *C. elegans*) para probar las técnicas. Los donantes fueron **20 voluntarios** y ~70% de la secuencia final vino de uno solo: la referencia **no** es de una persona ni un “genoma promedio”.

La línea de tiempo que piden ordenar

AÑO	HITO	LO QUE HAY QUE SABER
2001	Borradores: <i>Initial sequencing...</i> (Nature, consorcio) y <i>The Sequence of the Human Genome</i> (Science, Celera)	Eran drafts : gaps, regiones sin resolver, errores de ensamblado. No publicaron sólo secuencia: número y estructura de genes, exones/intrones, contenido GC, repetidos, transposones, duplicaciones, SNPs, evolución. Celera estimó 26.000-38.000 genes; el consorcio 30.000-40.000
2004	<i>Finishing the euchromatic sequence</i>	~2,85 Gb, sólo 341 gaps , ~99% de la euromatina , error ~1 en 100.000 bases, estimación de genes baja a 20.000-25.000. Seguían faltando centrómeros, regiones pericentroméricas y subteloméricas, duplicaciones segmentarias y brazos cortos acrocéntricos
2022	T2T · <i>The complete sequence of a human genome</i> (Nurk et al.)	Telómero a telómero de los 22 autosomas + X ; agregó o corrigió ~200 Mb. Combinó PacBio HiFi + Nanopore ultralong . Faltó el cromosoma Y porque la línea CHM13 (mola hidatidiforme) es 46,XX
2023	<i>The complete sequence of a human Y chromosome</i>	Genoma HG002. ~62,46 Mb, +30 Mb respecto de GRCh38. Difícil por repeticiones en tándem, palíndromos, duplicaciones segmentarias y heterocromatina: un problema de ensamblaje , no de química

El malentendido que buscan en el V/F

La heterocromatina no era difícil porque “esté compacta y la enzima no entre” (al extraer el ADN esa compactación se pierde): era difícil porque está llena de **secuencias repetitivas casi idénticas** y con reads cortas no se sabe en qué copia va cada una. Una long read atraviesa el bloque repetido y llega a secuencia única de los dos lados.

Secuenciar ≠ anotar

Secuenciación: ¿qué bases hay? **vs.** Anotación: ¿qué significa cada región?

La anotación busca patrones (promotores, sitio de inicio de transcripción, ATG, exones, intrones, sitios de splicing, codones stop, poliadenilación) y los cruza con evidencia: ARNm y ADNc conocidos, **ESTs**, proteínas, genes homólogos de otras especies, conservación, familias de dominios. Por eso una función puede asignarse **por homología** sin haber estudiado la proteína (anotación funcional predictiva, que después habría que confirmar).

Y por eso **el número de genes humanos no es un valor fijo**: GENCODE, Ensembl, RefSeq y CHESSE parten de la misma secuencia pero usan criterios distintos y reportan números distintos de codificantes, lncRNA, pseudogenes y transcriptos.

NGS: segunda generación

El salto es la **secuenciación masiva en paralelo**: millones de reacciones a la vez. Sanger necesitaría ~4,2 millones de reacciones (~42.000 placas de 96 pocillos, ~8 años) para 3,2 Gpb; NGS hace un genoma humano en **1 a 5 días**. Flujo general: fragmentación → adaptadores → amplificación → secuenciación → análisis bioinformático.

El cuello de botella se mudó: antes era generar la secuencia, ahora es almacenar, procesar, analizar e interpretar los datos.

TECNOLOGÍA	CÓMO DETECTA	DETALLES Y PROBLEMA
Pirosecuenciación (Roche 454)	Incorporación → PPi → cascada enzimática → luz	Un solo tipo de dNTP por ciclo (hay ciclos sin señal). Falla en homopolímeros : la intensidad no distingue bien 6, 7 u 8 bases iguales
Ion Torrent	Incorporación → H⁺ → cambio de potencial	Igual esquema, un dNTP por ciclo. Mismo problema con homopolímeros
Illumina	Los 4 nucleótidos juntos , cada uno con fluoróforo + terminador reversible	Tagmentación → librería → flow cell → PCR puente → clusters (amplifican la señal). Ciclo: incorporación → imaging → cleavage. Como entra una base por ciclo , resuelve bien los homopolímeros

Común a la 2ª generación: secuenciación por síntesis, muchísimas reacciones en paralelo, microfluídica con ciclos de agregado y lavado. Amplificación previa: PCR en emulsión (una bead = un fragmento = miles de copias) o PCR puente.

NGS: tercera generación

Nacen para resolver lo que las reads cortas no podían: regiones repetitivas y ensamblados de novo. Se basan en **single molecule sequencing** (molécula individual) y evitan la amplificación, que introduce errores de polimerasa.

PacBio (SMRT)

Sí es secuenciación por síntesis. Polimerasa + molécula única dentro de un

ZMW

, señal fluorescente

en tiempo real

. Con

hairpins

el fragmento se circulariza y la polimerasa lo lee varias vueltas →

secuencia consenso

de alta precisión (HiFi).

Oxford Nanopore

No

es secuenciación por síntesis: lectura directa. El ADN atraviesa un

nanoporo

y altera la

corriente iónica

; esos cambios se traducen en bases. Reads larguísimas, equipo portátil, resultados en tiempo real (no hay que esperar el fin de la corrida).

Short vs. long reads

Cortas (Illumina): muchísimas reads, alta precisión por base, bajo costo, ecosistema bioinformático enorme → ideales para SNPs conocidos, RNA-seq con muchas muestras, gran profundidad barata. **Largas (PacBio/Nanopore)**: atraviesan repetitivas, mejores para **de novo**, variantes estructurales, transcriptos completos, haplotipos, metagenómica. Fueron “Method of the Year” de Nature Methods en 2023.


Archivos, cobertura y multiplexado

FASTQ	Lo que devuelve el secuenciador: identificador + secuencia + calidad de cada base . La calidad cae hacia el final por la desincronización de las polimerasas dentro del cluster (la señal se vuelve difusa).
FASTA	Sólo identificador + secuencia. Se usa para el genoma de referencia.
Read	Secuencia continua obtenida en la corrida; un fragmento del ADN original.
Library	Todos los fragmentos preparados para secuenciar, con adaptadores y, si hace falta, barcodes .
Profundidad	Cuántas reads independientes cubren una posición. 30X = cada posición leída ~30 veces en promedio.
Single vs. paired-end	1 fragmento = 1 read, vs. 1 fragmento = 2 reads (una de cada extremo, con distancia conocida). Paired-end mejora mapeo, ensamblado, indels y variantes estructurales.
Multiplexado	Varias muestras en una corrida, cada una con su barcode ; después se demultiplexan. Como la máquina genera un total finito de reads, más muestras = menos profundidad por muestra .

Por qué importa la profundidad

Es un muestreo. Con 2 reads que dicen G podrías creer que es G/G por puro azar; con 100 reads (≈ 50 A / 50 G) tenés evidencia fuerte de heterocigosis. Y si de 100 reads 99 dicen A y una dice G, esa G probablemente sea un **error de secuenciación**.

De reads a variantes



- **Sin referencia** → ensamblado **de novo**: reads → solapamientos → contigs → scaffolds. Las repetitivas son el problema.
- **Con referencia** → alineamiento + **variant calling**: mucho más simple computacionalmente. El genoma de referencia es un **andamiaje**, no una lista de variantes patogénicas.
- Mapear es más difícil en genomas grandes y con reads cortas: más lugares donde podría encajar.

VCF = lista de diferencias respecto de la referencia: **CHROM**, **POS**, **REF**, **ALT**, **QUAL**, **INFO**. Un VCF sin anotar dice **qué** variante hay y **dónde**, no qué efecto tiene.

Cuánto genoma secuencio, y los SNP arrays

WGS	Genoma completo (de novo o contra referencia). Único que ve regiones reguladoras, intrónicas, no codificantes y variantes estructurales.
WES	Sólo el exoma (~1% del genoma, ~30 Mb) donde se concentra gran parte de las variantes de enfermedad conocidas.
Targeted	Regiones puntuales de interés. El WES es, conceptualmente, un targeted amplio.
¿Cómo se capturan?	Con sondas complementarias (hibridación) o con PCR de primers específicos, antes de armar la library.


SNP array ≠ secuenciación

Es una **plataforma de genotipificación**: cientos de miles de sondas para posiciones **ya conocidas y variables**; el ADN hibrida y la intensidad de fluorescencia dice qué genotipo hay. NGS pregunta “¿qué dice acá?”; el array pregunta “en esta posición, ¿tenés A o G?”. Sirven porque muchas variantes se heredan juntas por **desequilibrio de ligamiento**, así que un SNP marca una región entera. Es la tecnología de los servicios tipo 23andMe y la que hizo posibles los **GWAS** a gran escala.

Tipos de variantes: **SNV/SNP** (un nucleótido), **indels**, **estructurales** (deleciones, duplicaciones, inversiones, inserciones, translocaciones, cambios de número de copias). Y según su origen: **germinales** (heredables, en todas las células) o **somáticas** (aparecen durante la vida en un linaje celular).

Earth BioGenome Project: una biblioteca digital de la vida

Objetivo: un **genoma de referencia** de alta calidad para todas las especies eucariotas conocidas. Hoy tenemos secuencia de ~**1%** de los eucariotas. Dentro del EBP está el **Darwin Tree of Life** (~70.000 especies de Gran Bretaña e Irlanda).



Desafíos: escala logística, tecnología más rápida y barata, **anotación** (el paso más complejo: pasar de secuencia a biología), capacidad computacional (nube, “analizar una vez y reutilizar muchas veces”) y **acceso equitativo:** gran parte de la biodiversidad está en el Sur Global y las comunidades locales deben participar.

Para qué sirve: evolución y filogenia, adaptación al ambiente, conservación (lince ibérico, chancro del fresno), agricultura (parientes silvestres de cultivos, plagas, pesquerías), biotecnología. Datos de **acceso abierto:** secuencias, anotaciones, datos crudos, protocolos y herramientas.

De la referencia al individuo: los primeros genomas diploides

Las primeras referencias eran esencialmente **haploides** y compuestas (HGP: varios donantes; Celera: consenso de 5 individuos). Pero somos **diploides**: en cada posición hay dos alelos, uno materno y uno paterno.

HuRef · Levy et al. 2007

Primer genoma diploide individual. Mostró que la variabilidad no es sólo SNPs: indels, inversiones,

duplicaciones segmentarias

(>5 kb con >90% de identidad) y

62 CNVs

(ganancias y pérdidas), algunos afectando genes de OMIM. Los CNVs se detectaban con

CGH

y

SNP arrays

.

Watson · Wheeler et al. 2008

Por

secuenciación masiva en paralelo

, redundancia

7,4X

, ~2 meses y menos de US\$1 M (contra ~US\$100 M del genoma de Venter por Sanger). ~3,3 M de SNPs, ~10.654 con cambio de aminoácido, indels y CNVs de 26 kb a 1,5 Mb.

Un detalle fino que da puntos

En Watson, los SNPs **ya conocidos** estaban repartidos ~50/50 entre homocigotas y heterocigotas, pero los **nuevos** eran 83,3% heterocigotas. Tiene sentido: una variante nueva es rara en la población, así que es mucho más probable encontrarla en una sola copia.

Diversidad humana: África, cuellos de botella y admixture

Un solo genoma de referencia **no representa a la especie**. La mayor diversidad genética está en las poblaciones **africanas**: los humanos modernos surgieron en África y acumularon variación durante más tiempo. Al secuenciar individuos africanos (p. ej. el genoma Bushman/Khoisan, Schuster et al. 2010) aparecieron millones de SNPs **nuevos**, muchos en realidad **ancestrales** pero mal representados en las primeras referencias.

FENÓMENO	QUÉ PASA
Cuello de botella	Una población grande se reduce drásticamente por un evento; los sobrevivientes son una muestra azarosa. Al recuperarse el tamaño, la diversidad perdida no vuelve.
Efecto fundador	Un grupo pequeño se separa y funda una población nueva, llevando sólo parte de la diversidad original. Es lo que pasó al salir de África: la diversidad fuera de África es menor .
Población cerrada	Poco flujo génico externo → ciertos alelos se mantienen y la deriva genética pesa más.
Admixture	Qué proporción del genoma de un individuo corresponde a distintas poblaciones ancestrales (el gráfico de barras de colores). No es “de dónde sos”, es cómo se distribuyen tus variantes.

Las diferencias entre poblaciones no son “diferencias entre razas”: son variación acumulada durante la historia evolutiva. Hay que distinguir variantes **ancestrales** de **derivadas**.

Las bases de datos, una por una ★


BASE	PARA QUÉ ES	DETALLE QUE PREGUNTAN
dbSNP	Catálogo de identificadores (rsID) de variantes	Es infraestructura de nomenclatura , inclusiva y no curada : puede tener artefactos. La misma variante puede figurar como G→A o C→T según la hebra (rs4988235). Un rsID (rs113993960) no es lo mismo que un nombre descriptivo (ΔF508)
1000 Genomes	Catálogo de variabilidad poblacional (2008-2015): SNPs, indels, CNVs	Buscaba >95% de las variantes de frecuencia relativamente baja; da frecuencias por población, haplotipos y LD . Alta cobertura: 3202 muestras, 26 poblaciones, incluidas PUR y CLM (individuos admixados)
gnomAD	Frecuencias alélicas de cientos de miles de exomas y genomas	Es la base para filtrar por frecuencia hoy. Ej.: rs334 (HBB, anemia falciforme) tiene frecuencia global muy distinta de la africana
Ensembl	Información de una variante caracterizada	Alelo, cromosoma, posición, región, consecuencias predichas (p. ej. si cae en un intrón)
ENCODE	Catálogo de elementos funcionales : CHIP-seq, ATAC-seq, DNase-seq en muchos tipos celulares	Permite preguntar si una variante intrónica cae en un enhancer o promotor (intrón 1 de <i>FTO</i> ; región reguladora <i>LCT/MCM6</i>)
ClinVar	Interpretación clínica de variantes, aportada por laboratorios	No mires sólo la clasificación: mirá el review status (estrellas) y si hay conflictos entre submitters (típico en BRCA1 → problema de las VUS). rs113993960 en CFTR tiene miles de envíos concordantes
ClinGen	Cura la evidencia de la relación gen-enfermedad	Clasifica esa evidencia (Definitive... Limited, Disputed), evalúa dosage sensitivity (clave para CNVs, p. ej. 22q11.2) y publica especificaciones ACMG por gen. Que un gen esté en un panel comercial no significa que la evidencia sea sólida
PharmGKB	Farmacogenómica : gen-droga-nivel de evidencia	Define alelos estrella (*2, *3), que son haplotipos , no una variante suelta: por eso un rsID solo no alcanza. Ej.: CYP2C19 y clopidogrel (metabolizador pobre); CFTR e ivacaftor (el gen de la enfermedad es el blanco terapéutico)

ChIP-seq y la crítica a ENCODE

ChIP-seq responde: ¿esta proteína está unida al ADN, y en qué regiones? Anticuerpo específico (con beads magnéticas) → se recupera anticuerpo + proteína + ADN asociado → se secuencian ese ADN → se ve dónde mapea en el genoma.

ENCODE consideró “funcional” a un segmento si: se transcribe, tiene una histona modificada, está en cromatina abierta, tiene un factor de transcripción o tiene un CpG metilado. **La crítica:** eso describe un **estado molecular**, no demuestra una **función causal**. No es lo mismo “presenta características asociadas a actividad” que “cumple una función”.

GWAS: asociación, no causa ★




- En la recolección hay que controlar la **estratificación poblacional** y la admixture: si no, aparecen asociaciones que sólo reflejan diferencias entre poblaciones.
- El **Manhattan plot**: cada punto es un SNP ubicado por cromosoma; la altura es la fuerza de la asociación.
- **Asociación ≠ causalidad**. Un GWAS genera hipótesis; después hay que replicar en otra población (validación biológica) y demostrar el mecanismo (validación funcional), como pasó con C4.
- Que un gen esté **asociado** no lo vuelve **causante**. Una forma de sumar evidencia es la **cosegregación**: ver si la variante viaja con la enfermedad en varias generaciones de una familia.

Complemento: PRS (no está en tus resúmenes, pero cae en multiple choice)

Un **score de riesgo poligénico** se calcula genotipando SNPs conocidos de un individuo y sumando sus efectos, usando los **resultados de los GWAS** como pesos. Da un **riesgo relativo** para un fenotipo común, **no** diagnostica enfermedades mendelianas. Ésa es siempre la opción correcta: “el PRS usa resultados de GWAS para calcular la puntuación”.

El caso

Trío familiar: **padre + madre + hijo afectado** (proband). El chico tiene **osteopetrosis** y los padres son **consanguíneos y asintomáticos** → hipótesis de **herencia autosómica recesiva**: cada padre portador, el hijo con las dos copias alteradas.



¿Por qué exoma?

El exoma es ~**1% del genoma** (~30 Mb) pero concentra una proporción enorme de las variantes conocidas causantes de enfermedad. Es más barato que WGS y genera muchísimos menos datos.

La trampa favorita del TP

Aunque hagas WES vas a encontrar **variantes intrónicas**: el ADN se corta al azar y las sondas capturan también secuencia vecina al exón (que además es donde están las señales de **splicing**). Que aparezcan intrónicas no significa que el exoma “falló”.

Paso a paso, con la herramienta y la pregunta que responde

PASO	HERRAMIENTA	PREGUNTA QUE RESPONDE
Datos crudos	archivos <code>.fq.gz</code> , R1 y R2	Paired-end: cada fragmento leído de los dos extremos. Todavía no sé dónde va cada lectura
Control de calidad	FastQC + MultiQC	¿Los datos son confiables? Se mira GC content (en exoma no tiene por qué coincidir con el del genoma completo) y duplicación (puede venir de la captura y la amplificación)
Referencia	hg19 , cromosoma 8	Se usa sólo el cr. 8 porque ahí está el gen del fenotipo: archivos más chicos. En un análisis real sería todo el genoma (GRCh38)
Indexación	BWA index	No modifica la secuencia: crea archivos auxiliares para buscar rápido
Mapeo	BWA MEM → SAM	¿Dónde va cada read? Acá se agregan los read groups (ID, SM, PL) para distinguir padre ≠ madre ≠ hijo
Compresión y orden	Samtools → BAM + BAI	SAM es texto y pesa; BAM es binario. Sorting por posición, indexing para acceder rápido a una región
Posprocesamiento	filtrado de pares + deduplicación	Se conservan pares bien mapeados y se eliminan duplicados de PCR: si no, una sola molécula amplificada muchas veces infla la evidencia de una variante y distorsiona la frecuencia alélica
Variant calling	FreeBayes (joint calling del trío) → VCF	¿Qué difiere de la referencia? SNPs, indels, MNPs, eventos complejos. Analizar los tres juntos mejora la interpretación
Normalización	bcftools norm	Separa multialélicas y normaliza indels (left alignment) para poder cruzarlos con bases de datos
Anotación funcional	SnpEff	¿Qué significa? Gen, región, efecto (missense, stop_gained, frameshift, splice), IMPACT y HGVS
Filtrado	SnpSift	Herencia + impacto + frecuencia + evidencia clínica

Leer un VCF

Columnas

CHROM POS REF ALT QUAL + los datos de cada muestra.

Genotipos

0/0 homocigota de referencia · 0/1 heterocigota · 1/1 homocigota del alternativo.

Modelo recesivo

padre 0/1 + madre 0/1 + hijo 1/1.

QUAL

Confianza en el llamado, no peligrosidad. QUAL ≠ impacto biológico.

¿Ya encontramos la mutación? No.

Después del variant calling tenés muchísimas variantes y todavía no sabés si están en un gen, cuál, si cambian una proteína, si son frecuentes o si alguien ya las asoció a una enfermedad. Para eso hace falta **anotar e interpretar**.

IMPACT de SnpEff y nomenclatura HGVS

HIGH

Potencialmente muy disruptivo: stop_gained, frameshift, ciertos splice.

MODERATE

Posible efecto funcional importante: típicamente missense.

LOW

Efecto probablemente menor (p. ej. sinónimas).

MODIFIER

Difícil de interpretar o de menor impacto (intrónicas, intergénicas).

HGVS: c.290G>A = en la posición 290 del ADN codificante, una G cambia por A. p.Trp97* = en el aminoácido 97 (triptófano) aparece un codón de parada → proteína truncada.

Filtrado final y desenlace

Se combinan cuatro cosas: **herencia** (proband 1/1, padres 0/1) + **impacto** (HIGH o MODERATE) + **frecuencia** (<1%) + **evidencia clínica** (ClinVar). Queda una candidata: **CA2**, p.Trp97* (stop-gained) → deficiencia de anhidrasa carbónica II → osteopetrosis con acidosis tubular renal, que es exactamente el fenotipo.

Sobre las frecuencias

Una variante causal de enfermedad rara debería ser rara en la población (1000 Genomes da AF global y por población: EUR, AFR, AMR, EAS, SAS). Pero **AF = 0 no prueba** que no exista: puede que no se haya observado o que no haya cruzado bien con la base (típico en indels representados distinto).

Tendencia esperable: las variantes de **mayor impacto** tienden a ser **menos frecuentes**, porque la **selección purificadora** las elimina. Es una tendencia poblacional, no una regla para cada variante.

Las diferencias que no podés confundir

Mapeo

¿Dónde está mi lectura?

Variant calling

¿Qué diferencia hay entre mi muestra y la referencia?

Anotación

¿Qué significa esa diferencia?

Filtrado

¿Cuáles son compatibles con la enfermedad?

Interpretación

¿Qué evidencia tengo para decir que es patogénica?

Para el parcial importa explicar **por qué se pasa de un archivo al siguiente**, no memorizar comandos.


TP 1 • Del FASTQ a la variante

Análisis de datos de secuenciación de exomas para el diagnóstico de una enfermedad genética



EL CASO


Trío familiar: padre + madre + hijo afectado (proband).
Osteopetrosis · padres consanguíneos y asintomáticos.
Hipótesis: herencia autosómica recesiva.



El recorrido completo del TP 1: cada paso, la herramienta que lo hace, el archivo que produce y la pregunta que responde.

De dónde salen los datos

Se arranca directamente desde **VCF + pedigrí** (la primera mitad ya estaba hecha). Los datos base son de una familia real sana, **CEPH/Utah 1463**: NA12891 (padre), NA12892 (madre), NA12878 (hija). Sobre eso los docentes agregaron artificialmente una variante patogénica real y publicada (**spike-in**). El ejercicio es literalmente buscar **una aguja en un pajar**.



El pedigrí y los patrones de herencia ★

El **.tfam** trae familia, individuo, padre, madre, sexo y fenotipo. Códigos: **fenotipo** 1 = no afectado, 2 = afectado; **sexo** 1 = macho, 2 = hembra.

PATRÓN	HIJA	PADRE	MADRE
Autosómico recesivo	1/1	0/1	0/1
Dominante heredado del padre	0/1	0/1	0/0
Dominante heredado de la madre	0/1	0/0	0/1
Dominante de novo	0/1	0/0	0/0
Dominante no heredada (hija sana)	0/0	0/1	0/1

En este VCF los genotipos vienen **phased** (0|1): la barra vertical indica fase. Para el filtro no importa distinguir 0|1 de 1|0, así que se normalizan a 0/1.

Por qué el pedigrí filtra tanto

Si encontrás padre 0/0, madre 0/0 e hija 1/1, esa variante **no encaja** con un recesivo heredado: la hija no pudo recibir el alelo alternativo de ninguno de los dos.

GRCh38: el detalle que arruina todo si lo pasás por alto

El TP2 trabaja en **GRCh38**, mientras el TP1 usaba **GRCh37/hg19**. Las **coordenadas cambian** entre versiones: el VCF, la referencia FASTA, SnEff, ClinVar y 1000 Genomes tienen que ser **todos de la misma versión**. La referencia se descarga además porque hace falta para normalizar (sobre todo indels).

Anotar: qué agrega cada capa

bcftools norm	Separa multialélicas, normaliza y alinea indels a la izquierda → representación consistente para cruzar con bases externas.
SnEff	Gen, ubicación, efecto (missense, stop_gained, frameshift, splice), IMPACT y HGVSp .
ClinVar	¿Ya fue reportada? ¿Qué enfermedad? ¿Qué clasificación y qué review status ?
1000 Genomes	Frecuencia: AF global y EUR_AF , AFR_AF , AMR_AF , EAS_AF , SAS_AF .
UniProt	La proteína: ¿la variante cae en un dominio funcional conocido?
VarSome	Segunda mirada que integra fuentes y da una clasificación ACMG automática — para comparar con tu razonamiento, no para reemplazarlo.

Detalle técnico que preguntan

Antes de anotar con 1000 Genomes se **eliminan los campos AF/AC/AN propios** del VCF. Si no, cuando una variante no encuentra coincidencia podrías confundir la frecuencia de **tu trío** con la frecuencia **poblacional**.

Por qué casi todas las variantes son LOW/MODIFIER y casi ninguna está en ClinVar

Una persona sana tiene una enorme cantidad de variantes respecto de la referencia: la mayoría no afecta genes importantes, está en regiones no codificantes o es tolerada. Una variante que destruyera genes esenciales difícilmente se mantendría en la población. Y ClinVar sólo reúne variantes con relevancia clínica **estudiada y reportada**, así que “no reportado” es lo normal.

Tres cosas distintas

IMPACT ≠ **patogenicidad** (SnEff predice efecto funcional, no causalidad). **Raro** ≠ **patogénico**. **QUAL** ≠ **impacto**.

El orden correcto del razonamiento

1. ¿Cómo se hereda? (pedigrí)
2. ¿Qué impacto funcional tiene? (SnEff)
3. ¿Qué tan frecuente es? (1000 Genomes / gnomAD)
4. ¿Hay evidencia clínica previa? (ClinVar)
5. ¿El gen tiene relación con la enfermedad? (ClinGen, OMIM, UniProt)
6. ¿Toda la evidencia junta alcanza para llamarla patogénica? (ACMG/AMP)

No es “veo una HIGH y digo que es la causante”.

Criterios ACMG/AMP ★

Cinco categorías: **Patogénica** · **Probablemente patogénica** · **VUS** · **Probablemente benigna** · **Benigna**.

CRITERIO	PESO	QUÉ DICE	DE DÓNDE SALE EN EL TP
PVS1	Muy fuerte	Variante de pérdida de función (nonsense, frameshift, splicing) en un gen donde la LoF es mecanismo conocido de enfermedad	SnEff: HIGH + stop_gained/frameshift
PS1 / PM5	Fuerte / Moderado	PS1: la misma variante ya fue reportada patogénica. PM5: otra variante patogénica afecta el mismo codón	ClinVar
PM2	Moderado	Ausente o extremadamente rara en poblaciones de referencia	1000 Genomes / gnomAD
PP1	De apoyo	Cosegrega con la enfermedad en la familia (hijo 1/1, padres 0/1)	Pedigrí
PP4	De apoyo	El fenotipo del paciente coincide fuertemente con la enfermedad del gen	Clínica + OMIM
BA1 / BS1	En contra	Demasiado frecuente para ser compatible con una enfermedad rara → evidencia de que no es patogénica	1000 Genomes / gnomAD

En el TP1, PVS1 + PM2 + PP1 + PP4 → **patogénica**. No se pudo usar PS1 porque ClinVar no tenía clasificación previa para esa variante.

La frase que resume el TP

“Tengo miles de variantes porque cada individuo presenta mucha variabilidad genética. Uso el **pedigrí** para determinar qué patrón de herencia debería tener la variante causal. Después agrego información sobre su **impacto funcional**, su **frecuencia poblacional** y la **evidencia clínica**. Al combinar todos esos datos reduzco las variantes a unas pocas candidatas y finalmente evalúo, con los criterios **ACMG/AMP**, si alguna tiene suficiente evidencia para considerarla patogénica.”

TP 2 • Anotar, filtrar y clasificar

Del VCF de un trío familiar a una variante candidata clasificada con criterios ACMG/AMP



LOS DATOS

Familia real sana CEPH/Utah 1463: NA12891 (padre), NA12892 (madre), NA12878 (hija). Los docentes agregaron una variante patogénica real y publicada (spike-in).

1

El pedigrí decide qué busco

VCF + archivo .tfam

El .tfam trae familia, individuo, padre, madre, sexo y fenotipo. Fenotipo: 1 = no afectado, 2 = afectado. Sexo: 1 = macho, 2 = hembra.

patrón de herencia	hija	padre	madre
Autosómico recesivo	1/1	0/1	0/1
Dominante del padre	0/1	0/1	0/0
Dominante de la madre	0/1	0/0	0/1
Dominante de novo	0/1	0/0	0/0
No heredada (hija sana)	0/0	0/1	0/1

0 = alelo de referencia · 1 = alelo alternativo · 0/1 phased se normaliza a 0/1

2

Anotar: capas de información sobre el mismo VCF

bcftools norm	separa multialélicas · alineando indels a la izquierda
SnEff	gen · efecto · IMPACT (HIGH...MODIFIER) · HGVSp p.Trp97*
ClinVar	¿ya fue reportada? clasificación + review status (estrellas)
1000 Genomes	AF global y por población (EUR, AFR, AMR, EAS, SAS)

El VCF es siempre el mismo archivo: cada herramienta le agrega columnas de información.

3

Filtrar: recién acá se descartan variantes

miles de variantes	una persona sana difiere mucho de la referencia
patrón de herencia	hija 1/1 · padre 0/1 · madre 0/1
IMPACT HIGH o MODERATE	priorizo lo que puede alterar la proteína
frecuencia < 5%	una enfermedad rara no viene de una variante común
unas pocas candidatas	ahora sí miro variante por variante

4

Interpretar: combinar la evidencia con los criterios ACMG/AMP

PVS1	muy fuerte	pérdida de función (nonsense, frameshift, splicing) en un gen donde la LoF causa la enfermedad	SnEff · IMPACT HIGH
PS1 / PM5	fuerte / moderado	la misma variante ya fue reportada patogénica / otra patogénica afecta el mismo codón	ClinVar
PM2	moderado	ausente o extremadamente rara en poblaciones de referencia	1000 Genomes · gnomAD
PP1	de apoyo	cosegrega con la enfermedad dentro de la familia	pedigrí .tfam
PP4	de apoyo	el fenotipo del paciente coincide con la enfermedad del gen	clínica · OMIM · UniProt
BA1 / BS1	en contra	demasiado frecuente para una enfermedad rara → evidencia de que NO es patogénica	1000 Genomes · gnomAD
BENIGNA · PROB. BENIGNA · VUS · PROB. PATOGENICA · PATOGENICA			

LO QUE MÁS SE PIERDE PUNTOS

Todo tiene que estar en la MISMA versión del genoma: VCF, FASTA, SnEff, ClinVar y 1000 Genomes (acá, GRCh38). Las coordenadas cambian entre GRCh37 y GRCh38. Antes de anotar con 1000 Genomes se sacan los campos AF/AC/AN propios del VCF: si no, confundís la frecuencia de tu trío con la frecuencia poblacional. IMPACT ≠ patogénica · raro ≠ patogénico · la mayoría de las variantes son LOW/MODIFIER y no están en ClinVar: es lo esperable.

El TP 2 en una imagen: el pedigrí define qué buscar, la anotación agrega capas de información, el filtro recorta y ACMG clasifica.

Qué es el cfDNA y por qué importa

Revisión de Bianchi y Chiu (NEJM, 2018). El **ADN libre circulante** son fragmentos de ADN que circulan en el plasma, fuera de células. En el embarazo el plasma materno tiene cfDNA **materno** y cfDNA **placentario** (sobre todo del trofoblasto), que se libera durante la fusión y apoptosis normales de los citotrofoblastos y sincitiotrofoblastos.

La idea central de todo el paper

Se lo llama “ADN fetal” pero en realidad viene de la **placenta**, y el genoma placentario **no siempre coincide** con el fetal. Por eso es un **test de tamizaje (screening)**, **no diagnóstico**: todo positivo se confirma con una prueba invasiva.

Fracción fetal ★

Es la proporción del cfDNA total del plasma que proviene de la placenta. **Aumenta con la edad gestacional**, y por eso el test se hace desde la **semana 10**: recién ahí suele haber suficiente ADN placentario para un resultado informativo. Si es demasiado baja, el resultado es un “**no call**” (no concluyente), que **no** debe leerse como normal: a veces se asocia a una alteración cromosómica.

Causas de fracción fetal baja: obesidad materna (más apoptosis de adipocitos → más cfDNA *materno*, así que baja la *proporción* aunque el ADN placentario no haya bajado), embarazo muy temprano, reproducción asistida, gestación múltiple, heparina, trastornos tromboembólicos, déficit de vitamina B12, triploidía digénica.

La precisión no depende sólo de la fracción fetal: también de cuántas moléculas se secuenciaron, la cobertura, el contenido GC de cada cromosoma, la presencia de CNVs, la calidad de la muestra y los algoritmos bioinformáticos.

Los dos métodos

Secuenciación aleatoria (genome-wide)

Se secuencian al azar millones de fragmentos, se alinean contra la referencia, se cuenta cuántos vienen de cada cromosoma y se compara esa proporción con embarazos euploides. En una trisomía 21 hay un

pequeño exceso

de fragmentos del cr. 21. No se secuencian un cromosoma fetal aislado: se detecta un

desbalance cuantitativo

mínimo.

Secuenciación dirigida

Sólo cromosomas o regiones de interés (13, 18, 21). Un enfoque amplifica y secuencia

SNPs informativos

y compara las

proporciones alélicas

: en un locus heterocigota se espera ~1:1; una copia extra desvía esa relación.

Es el mejor ejemplo de que la secuenciación puede usarse de manera **cuantitativa** (contar), no sólo para leer letras.

Rendimiento: sensibilidad, especificidad y VPP

Sensibilidad De los fetos que **sí** tienen la alteración, ¿cuántos detecto? (T21 ~97%, T18 ~93%, T13 ~95%)

Especificidad De los que **no** la tienen, ¿cuántos dan negativo? (~99,7-99,9%)

VPP Si dio positivo, ¿qué probabilidad hay de que sea real? **Depende de la prevalencia**: en alto riesgo T21 ~91%; en bajo riesgo baja a ~82% (T21), ~37% (T18) y ~49% (T13), aunque sensibilidad y especificidad sean iguales.

Contra el screening tradicional (marcadores séricos + translucencia nuchal + edad materna) el cfDNA tiene más sensibilidad, menos falsos positivos (menos de una décima parte) y mejor VPP: eso redujo entre **40% y 76%** los procedimientos invasivos (amniocentesis, biopsia corial).

Por qué falla cuando falla

FALSOS POSITIVOS	FALSOS NEGATIVOS
• Mosaicismo placentario confinado (la placenta es aneuploide y el feto no) — típico en T13 y monosomía X • Mosaicismo fetal • Gemelo evanescente (su placenta sigue liberando cfDNA) • Alteraciones cromosómicas maternas (mosaicismos 45,X o 47,XXX, CNVs benignas). Dos tercios de los casos discordantes con seguimiento se explicaron por hallazgos maternos • Cáncer materno (ADN tumoral con múltiples desbalances), leiomiomas uterinos • Trasplante de médula de donante masculino → aparente discordancia de sexo	• Fracción fetal baja • Obesidad materna • Gestación múltiple • Triploidía • Mosaicismo fetal • Placenta euploide con feto aneuploide (mosaicismo placentario “inverso”) • Mala calidad del cfDNA

Confirmación: para T13 o monosomía X conviene **amniocentesis** (representa mejor al feto); para T18 o T21 puede alcanzar la **biopsia corial** (analiza placenta). Un resultado **negativo** no descarta todo: las trisomías comunes son sólo ~un tercio de las anomalías que ve un cariotipo o un microarray.

Anexo • tablas y chuletas

1 • El camino de los archivos

FASTQ → SAM → BAM + BAI → VCF → VCF anotado

ARCHIVO	QUÉ CONTIENE	SE GENERA CON
FASTQ	Reads crudas + calidad por base	El secuenciador (R1 y R2 si es paired-end)
FASTA	Sólo identificador + secuencia	Es el formato del genoma de referencia
SAM	Lecturas alineadas , en texto	BWA MEM
BAM / BAI	Lo mismo en binario / su índice	Samtools (view, sort, index)
VCF	Variantes + genotipos: CHROM, POS, REF, ALT, QUAL, INFO	FreeBayes (variant calling), bcftools norm
VCF anotado	+ gen, efecto, IMPACT, HGVS, ClinVar, frecuencias	SnpEff / SnpSift
PED / .tfam	Pedigrí: familia, individuo, padre, madre, sexo, fenotipo	Lo arma quien diseña el estudio
HTML	Reportes de FastQC/MultiQC y resumen de SnpEff	FastQC, MultiQC, SnpEff

2 • Cada herramienta y la pregunta que responde

HERRAMIENTA	PREGUNTA
FastQC / MultiQC	¿Qué calidad tienen mis lecturas? ¿Cómo se ven todas juntas?
BWA MEM	¿Dónde va cada lectura en el genoma?
Samtools	¿Cómo proceso, ordeno e indexo los alineamientos?
FreeBayes	¿Qué variantes hay respecto de la referencia?
bcftools norm	¿Cómo normalizo el VCF para poder compararlo con bases externas?
SnpEff	¿Qué efecto funcional tiene cada variante?
SnpSift	¿Cómo anoto y filtro según criterios?
ClinVar	¿Ya hay información clínica sobre esta variante?
1000 Genomes / gnomAD	¿Qué tan frecuente es en la población?
UniProt	¿Cae en un dominio funcional de la proteína?
ACMG/AMP	¿Cómo integro toda la evidencia para clasificarla?
IGV	¿Cómo se ven las lecturas alineadas en esa posición? (profundidad, proporción de alelos)

3 • Tecnologías de secuenciación, una al lado de la otra

TECNOLOGÍA	GEN.	¿POR SÍNTESIS?	DETECCIÓN	FUERTE / DÉBIL
Sanger	1 ^a	Sí	ddNTP fluorescentes, electroforesis capilar	Alta calidad, sigue siendo el estándar de validación técnica / Muy baja escala
454 • Pirosecuenciación	2 ^a	Sí	PPi → luz	Lecturas más largas que Illumina en su momento / Homopolímeros
Ion Torrent	2 ^a	Sí	H ⁺ → cambio de potencial	Rápido, sin óptica / Homopolímeros
Illumina	2 ^a	Sí	Fluoróforos + terminadores reversibles (bridge PCR, clusters)	Throughput enorme, bajo costo por base, alta precisión, paired-end / Reads cortas : repetitivas y de novo
PacBio SMRT	3 ^a	Sí	Fluorescencia en tiempo real en un ZMW	Long reads, consenso HiFi de alta precisión / Costo
Oxford Nanopore	3 ^a	No	Cambios en la corriente iónica al pasar por el nanoporo	Reads ultra largas, portátil, tiempo real / Mayor error por base individual
SNP array	—	No es secuenciación	Hibridación con sondas + fluorescencia	Barato, masivo, base de los GWAS / Sólo posiciones ya conocidas

4 • Los patrones de herencia en el VCF

PATRÓN	AFFECTADO/A	PADRE	MADRE	PISTA CLÍNICA
Autosómico recesivo	1/1	0/1	0/1	Padres sanos, a menudo consanguíneos
Dominante del padre	0/1	0/1	0/0	Padre afectado o con expresividad variable
Dominante de la madre	0/1	0/0	0/1	Madre afectada
Dominante de novo	0/1	0/0	0/0	Padres sanos, caso aislado
No heredada	0/0	0/1	0/1	La hija sana no recibió la variante

0 = alelo de referencia · 1 = alelo alternativo · I = phased (con fase) · / = sin fase.

5 • Cómo responder las preguntas “inventá un experimento”

La cátedra repite el mismo molde en casi todos los exámenes. Si te falta algo del molde, perdés puntos aunque lo que digas esté bien.

1. **Hipótesis o pregunta** concreta, con moléculas y organismos reales (no “el gen X en la enfermedad Y”).
2. **Diseño experimental**: qué grupos comparo (casos/controles, tratado/no tratado), **réplicas biológicas**, cómo tomo la muestra, en qué momento y lugar, qué extraigo.
3. **Qué técnica elijo y por qué**: WGS / WES / panel / SNP array, short o long reads, profundidad. Justificar siempre con la pregunta.
4. **Qué datos obtengo** (archivos: FASTQ, VCF...) vs. **qué información obtengo** (variantes anotadas, genes candidatos).
5. **Inventá un resultado concreto** (con números o genes: “la variante aparece en el 85% de un grupo y el 10% del otro”).
6. **Validación técnica** (Sanger, qPCR: ¿la medición es real?), **biológica** (otra cohorte) y **funcional** (knockout, CRISPR, modelo animal: ¿es causal?).
7. **Nueva hipótesis** que se desprende del resultado, si la piden.

6 • Los 10 errores que anulan una respuesta

- Decir que un **exoma** informa sobre expresión o abundancia de transcriptos.
- Confundir **QUAL** (confianza del llamado) con impacto o patogenicidad.
- Confundir **IMPACT HIGH** (predicción funcional) con “patogénica”.
- Decir que el **llamado** de variantes agrega información biológica (eso es la **anotación**).
- Decir que las variantes se guardan en un **FASTQ** (van en el **VCF**).
- Afirmar que las reads **cortas** son las buenas para de novo y repetitivas.
- Decir que **toda** la 3ª generación es por síntesis (Nanopore no).
- Tratar una **asociación** de GWAS como causa, o usar GWAS para diagnosticar.
- Decir que salir de África **aumentó** la diversidad (la redujo: efecto fundador).
- Afirmar que **AF = 0** demuestra que la variante no existe en la población.

7 • Qué aparece en los modelos viejos y NO está en tus resúmenes

Estos temas son de la parte de **transcriptómica y proteómica** de la materia (y de finales, no del primer parcial). Los dejo listados para que los reconozcas y no te frenes:

Transcriptómica

RNA-seq, diseño experimental de expresión, count matrix, análisis de expresión diferencial, p-valor ajustado, volcano plot y heatmaps, ontología génica y análisis de enriquecimiento, microarrays vs. RNA-seq, single-cell RNA-seq, alineadores splice-aware.

Proteómica

Espectrometría de masas, huella peptídica (peptide mass fingerprinting), MALDI-TOF/TOF, MASCOT, modificaciones fijas y variables, mass tolerance y número de hits, geles bidimensionales, MS cuantitativa, correlación ARNm-proteína.

Cáncer y cBioPortal

Variantes somáticas vs. germinales en tumores, secuenciar tumor + tejido normal, mutaciones driver, oncoprints y curvas de sobrevida en cBioPortal.

Lo único de esa lista que sí conviene tener a mano para el parcial es el concepto de **PRS** (aparece junto a GWAS en un multiple choice recurrente): está explicado al final de la Unidad 3.

Anexo · glosario

ACMG/AMP. Criterios para clasificar variantes en patogénica, probablemente patogénica, VUS, probablemente benigna o benigna.

Admixture. Proporción del genoma de un individuo atribuible a distintas poblaciones ancestrales.

Alelo estrella (*2, *3). Haplotipo farmacogenómico definido en PharmGKB: una combinación de variantes, no un único rsID.

Anotación. Agregar información biológica a una secuencia o a una variante: gen, exón/intrón, efecto, impacto, frecuencia, evidencia clínica.

BAC. Bacterial Artificial Chromosome: vector usado por el HGP para clonar fragmentos grandes y construir el mapa físico.

BAM / BAI. Alineamientos en formato binario / su índice, que permite acceder rápido a una región.

Barcode. Etiqueta de secuencia que identifica de qué muestra viene cada fragmento cuando se multiplexan varias en una corrida.

Bridge PCR. Amplificación en puente sobre la flow cell de Illumina que genera los clusters de copias idénticas.

cfDNA. ADN libre circulante en plasma. En el embarazo mezcla ADN materno y placentario.

ChIP-seq. Inmunoprecipitación de cromatina + secuenciación: dice en qué regiones del ADN está unida una proteína.

ClinGen. Cura la evidencia de las relaciones gen-enfermedad y la sensibilidad a la dosis génica.

ClinVar. Repositorio de variantes con su interpretación clínica; mirar review status (estrellas) y conflictos.

Cluster. Conjunto de copias idénticas de un fragmento sobre la flow cell; amplifica la señal fluorescente.

CNV. Copy Number Variant: cambio en el número de copias de una región del genoma.

Cobertura / profundidad. Cuántas reads independientes cubren una posición (30X = ~30 veces en promedio).

Cosegregación. Que una variante se herede junto con la enfermedad dentro de una familia; suma evidencia de causalidad.

Cuello de botella. Reducción drástica del tamaño de una población, con pérdida de diversidad genética.

dbSNP. Catálogo de identificadores (rsID) de variantes. Inclusivo y no curado.

De novo (ensamblado). Reconstruir un genoma sin referencia, buscando solapamientos entre reads.

De novo (variante). Variante presente en el hijo y ausente en ambos padres.

Deduplicación. Eliminar copias generadas por PCR para no sobreestimar la evidencia de una variante.

Desequilibrio de ligamiento (LD). Tendencia de variantes cercanas a heredarse juntas; permite que un SNP marque toda una región.

Duplicación segmentaria. Región de más de 5 kb con más del 90% de identidad de secuencia.

Efecto fundador. Un grupo pequeño se separa y funda una población nueva llevando sólo parte de la diversidad original.

ENCODE. Proyecto que cataloga elementos funcionales del genoma (ChIP-seq, ATAC-seq, DNase-seq) en muchos tipos celulares.

Epigenoma. Conjunto de modificaciones que regulan la expresión sin cambiar la secuencia: metilación, histonas, cromatina.

EST. Expressed Sequence Tag: fragmento de ADNc de un transcripto; ayuda a localizar exones al anotar.

Exoma (WES). Conjunto de exones (~1-2% del genoma), donde se concentran muchas variantes de enfermedad.

FASTA. Identificador + secuencia. Formato del genoma de referencia.

FASTQ. Reads + calidad por base. Lo que devuelve el secuenciador.

Flow cell. Superficie de Illumina con oligos donde se unen los fragmentos y se forman los clusters.

Fracción fetal. Proporción del cfDNA del plasma materno que proviene de la placenta; aumenta con la gestación.

gnomAD. Base de frecuencias alélicas por población, construida con cientos de miles de exomas y genomas.

GWAS. Estudio de asociación de todo el genoma: casos vs. controles. Da asociación, no causalidad.

HGVS. Nomenclatura de variantes: c. a nivel de ADN codificante, p. a nivel de proteína.

Hierarchical shotgun. Estrategia del HGP: mapear primero (BACs, mapa físico) y secuenciar después.

Homopolímero. Serie de bases idénticas consecutivas; complica a 454 e Ion Torrent.

IMPACT. Nivel de efecto predicho por SnpEff: HIGH, MODERATE, LOW, MODIFIER. No es patogenicidad.

Indel. Inserción o delección de uno o pocos nucleótidos.

Joint calling. Llamar variantes de todas las muestras del trío a la vez para aprovechar la información familiar.

LINE / SINE. Retrotransposones: LINE ~21% del genoma y codifican transcriptasa reversa; SINE ~13% (Alu) y usan la de los LINE.

Long reads. Lecturas largas (PacBio, Nanopore) que atraviesan regiones repetitivas y facilitan el ensamblado.

Mapeo. Determinar en qué posición del genoma de referencia va cada read.

Metagenómica. Estudio del material genético de una comunidad completa, sin cultivar los microorganismos.

Multiplexado. Secuenciar varias muestras juntas con barcodes; reduce la profundidad por muestra.

Nanoporo. Poro en una membrana que, al ser atravesado por el ADN, altera la corriente iónica: base de Nanopore.

No call. Resultado no concluyente del cfDNA, típicamente por fracción fetal baja. No equivale a normal.

Nucleosoma. ADN (~146 pb) enrollado alrededor de un octámero de histonas.

ORF. Marco abierto de lectura: de un codón de inicio a un codón stop; posible región codificante.

Paired-end. Secuenciar los dos extremos del mismo fragmento; mejora mapeo, ensamblado y detección de variantes estructurales.

PharmGKB. Base de farmacogenómica: gen, droga, nivel de evidencia y alelos estrella.

Pseudogén. Secuencia derivada de un gen que perdió funcionalidad; sin intrones si vino de retrotranscripción.

PVS1 / PM2 / PP1 / PP4. Criterios ACMG: LoF en gen con mecanismo conocido / ausencia en poblaciones / cosegregación / fenotipo específico.

QUAL. Confianza en que el llamado de variante sea real. No indica patogenicidad.

Read group. Metadatos (ID, SM, PL) que identifican de qué muestra y lote viene cada lectura.

rsID. Identificador estable de una variante en dbSNP (ej.: rs334).

SAM. Alineamientos en formato de texto, salida de BWA MEM.

Selección purificadora. Eliminación de variantes deletéreas de la población; por eso las de alto impacto suelen ser raras.

Single molecule sequencing. Secuenciar moléculas individuales sin amplificación previa: base de la 3ª generación.

SNP array. Plataforma de genotipificación de posiciones conocidas por hibridación y fluorescencia. No es secuenciación.

SNV / SNP. Variante de un solo nucleótido; SNP es la que tiene cierta frecuencia poblacional.

Spike-in. Variante patogénica real agregada artificialmente a un dataset, como en el TP2.

Splicing alternativo. Distintas combinaciones de exones a partir de un mismo gen; ~95% de los genes multiexónicos.

T2T. Telomere-to-Telomere: ensamblado continuo de punta a punta (2022 autosomas + X; 2023 el Y).

Targeted sequencing. Secuenciar sólo regiones específicas de interés previamente seleccionadas.

Transcriptoma. Todos los ARN de una célula en un momento y condición dados.

Transposón. Secuencia de ADN capaz de moverse en el genoma; clase I con ARN intermediario, clase II con transposasa.

Trío. Padre, madre y proband secuenciados juntos para usar el patrón de herencia como filtro.

VCF. Variant Call Format: lista de variantes con CHROM, POS, REF, ALT, QUAL, INFO y genotipos.

VPP. Valor predictivo positivo: si el test dio positivo, probabilidad de que sea real. Depende de la prevalencia.

VUS. Variante de significado incierto: no hay evidencia suficiente para clasificarla.

WGS. Whole Genome Sequencing: todo el genoma, incluidas regiones reguladoras y no codificantes.

Whole-genome shotgun. Estrategia de Celera: fragmentar todo, secuenciar y ensamblar por computadora.

ZMW. Zero-Mode Waveguide: pocillo donde PacBio observa una polimerasa en tiempo real.

74 términos. Versión interactiva, flashcards, banco de preguntas y simulacros en la página de estudio del repositorio.